

Informe Proyecto Machine Learning

Gonzalo García Martínez-Echevarría

May 4, 2025

1 Introducción

El presente proyecto tiene como objetivo el análisis de un conjunto de datos relacionados con el rendimiento académico de estudiantes, considerando para ello múltiples variables asociadas a cada alumno. El objetivo principal es desarrollar modelos predictivos capaces de estimar la calificación final del tercer trimestre (T3) a partir de dicha información.

A lo largo del trabajo se han aplicado los conocimientos adquiridos en la asignatura de Aprendizaje Automático, incluyendo técnicas de preprocesamiento, exploración de datos, modelado supervisado y no supervisado. Además, se ha reutilizado y adaptado código desarrollado previamente en las prácticas entregables, integrándolo en el flujo de trabajo del proyecto para facilitar el desarrollo e implementación de los modelos.

2 Exploración inicial y tratamiento del conjunto de datos

2.1 Análisis de los datos.

Se comenzó con una revisión general del conjunto de datos, compuesto por múltiples variables. A pesar de la riqueza informativa, el número total de muestras es limitado, lo que condicionó algunas decisiones de modelado y preprocesamiento adoptadas más adelante.

Clasificación de variables en tres grupos principales para facilitar su análisis:

- **Categorías**, como `sexo`, `asignatura` o `internet`.
- **Discretas**, como el número de suspensos o el tiempo de estudio.
- **Continuas**, como la salud o la edad.

Se exploraron sus distribuciones mediante histogramas y boxplots. En este proceso se detectaron valores atípicos en la variable `faltas`, donde aparecían valores decimales que no eran coherentes. Estos valores fueron tratados como anómalos, convertidos en nulos e imputados posteriormente.




Figure 1: Boxplot de la variable `faltas`.

2.2 Procesamiento de los datos.

Tratamiento de datos faltantes. Algunas variables contenían valores nulos. Se evitó la eliminación de observaciones completas para preservar el tamaño muestral. En su lugar, se aplicó imputación utilizando la media de cada variable. Se exploraron posibles patrones en la distribución de los valores faltantes, sin encontrar correlaciones destacables.

Codificación y selección de variables. Las variables categóricas fueron transformadas mediante *one-hot encoding*, omitiendo la primera categoría para evitar multicolinealidad.

2.3 Modificación de variables.

Con el objetivo de capturar interacciones entre variables relevantes, se creó una nueva variable:

$$T1_T2_interaction = T1 \cdot T2 \quad (1)$$

Esta variable busca modelar el efecto combinado del rendimiento parcial sobre la nota final. Su utilidad se hizo evidente al detectar casos de alumnos con calificaciones iguales a cero tanto en la segunda como en la tercera evaluación, lo que sugiere patrones extremos de abandono o falta de progreso.

Además, se observó que cuando los valores de consumo de alcohol durante la semana escolar (**AlcSem**) y durante el fin de semana (**AlcFin**) son altos, la calificación final (**T3**) tiende a reducirse. Por tanto, se decidió combinar ambas variables en una sola, ponderando su influencia en función de la duración relativa de cada periodo dentro de una semana (5 días lectivos frente a 2 días de fin de semana):

$$Alc_comb = \frac{5}{7} \cdot AlcSem + \frac{2}{7} \cdot AlcFin \quad (2)$$

Una vez generada esta variable compuesta, se eliminaron las columnas originales **AlcSem** y **AlcFin** para evitar redundancias y reducir la dimensionalidad.

Adicionalmente, se realizó una transformación sobre las variables **Mtrab** y **Ptrab**, que inicialmente generaban 8 columnas tras la codificación one-hot (al tener 4 categorías cada una: *docencia*, *otros*, *sanidad* y *servicios*). Se observó que las distribuciones de **T3** eran similares para las mismas ocupaciones entre madre y padre, por lo que se decidió agruparlas en una única variable por tipo de ocupación, reduciendo así la dimensionalidad sin pérdida significativa de información.




Figure 2: Distribuciones de T3 de **Mtrab** y **Ptrab**.

3 Implementación y comparación de los modelos predictivos

Se experimentó con dos configuraciones distintas de conjuntos de datos:

- **X1**, que incluye todas las variables disponibles, incluyendo T1, T2 y la nueva variable T1_T2_interaction.
- **X2**, que excluye deliberadamente T1, T2 y la interacción, simulando un contexto donde no se dispone de notas previas.

En ambos casos, la variable objetivo fue T3. Los modelos fueron validados con **validación cruzada de 5 folds** y optimización de hiperparámetros mediante **GridSearchCV**. Se emplearon métricas como MAE, MSE y R^2 para evaluar el rendimiento.

3.1 Modelo 1.

He creado un modelo base llamado **T2Predictor** que consiste en utilizar únicamente la calificación del segundo trimestre (T2) como predictor de la nota final (T3). Su funcionamiento se basa en ajustar una función lineal de la forma:

$$\widehat{T3} = \alpha \cdot T2 + \beta \quad (3)$$

donde α representa el coeficiente de regresión (pendiente) y β el término independiente (intercepto). Para estimar estos parámetros, el modelo utiliza la solución analítica de mínimos cuadrados con término independiente, calculada como:

$$\boldsymbol{\theta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \quad (4)$$

donde $\mathbf{X}$ es la matriz con una columna para la variable T2 y otra columna de unos para el intercepto, y $\mathbf{y}$ es el vector de valores observados de T3. Todos lograron errores absolutos inferiores a 1 punto, demostrando una gran capacidad predictiva cuando se incluyen las calificaciones parciales.

Modelo	MAE	MSE	R^2
XGBoost	0.896	1.918	0.885
RandomForest	0.912	1.969	0.882
ElasticNet	0.941	2.469	0.852
LinearRegression	0.973	2.504	0.850
T2Predictor	0.955	2.627	0.842
SVR	1.006	2.828	0.830

Table 1: Rendimiento en test de los modelos entrenados con todas las variables (Modelo 1).

3.2 Modelo 2.

He creado un nuevo modelo como base llamado **MediaPredictor**, que predice siempre la media, nos dió de resultado su valor teórico aproximado, un $R^2 \approx 0$. El rendimiento general disminuyó notablemente al eliminar las notas anteriores.

Modelo	MAE	MSE	R^2
XGBoost	2.321	9.510	0.429
RandomForest	2.378	9.797	0.412
ElasticNet	2.518	12.205	0.267
MLP	2.835	12.960	0.222
KNN	2.774	13.865	0.168
MediaPredictor	2.981	16.701	-0.003

Table 2: Rendimiento en test de los modelos sin calificaciones previas (Modelo 2).

3.3 Algoritmos comunes.

Los algoritmos más interesantes fueron utilizados para ambos modelos. Los tres estuvieron en el podio y en el mismo orden en ambos casos. Primero **XGBoostRegressor** que obtuvo los mejores resultados ya que es un modelo basado en árboles en el que se utilizan diferentes árboles de regresión para predecir la variable objetivo. Le siguió de cerca **RandomForest** que es otro modelo basado en árboles de regresión solo que algo menos complejo. Por último pero no menos importante **ElasticNet** alcanzó buenos rendimientos pese a ser un modelo lineal.

4 Análisis interpretativo de los resultados obtenidos

Los resultados muestran una clara diferencia de rendimiento entre los modelos entrenados con y sin acceso a las calificaciones previas (T1 y T2).

4.1 Modelo 1.

En el **Modelo 1**, prácticamente todos los algoritmos ofrecieron valores de R^2 superiores a 0.83, con errores absolutos medios inferiores a 1 punto. Esto evidencia que la información parcial del curso es un predictor extremadamente potente de la nota final.

Este modelo resulta útil como referencia base porque permite evaluar cuánto poder predictivo tiene exclusivamente la nota del segundo trimestre. En este proyecto, **T2Predictor** mostró un rendimiento notablemente alto ($R^2 = 0.84$), lo que confirma que T2 es una variable altamente informativa para predecir T3.

El modelo de **LinearRegression** que obtuvo una performance de $R^2 = 0.85$, fue el programado en la práctica de la asignatura y ha sido reutilizado para este trabajo. Ha obtenido unos resultados bastante buenos no se esperaba haber conseguido programar un modelo que diese tan buenos resultados. Por otra parte **SVR** pese a no obtener un resultado malo ($R^2 = 0.83$), predijo peor los datos que modelos muy simples lo que nos indica que no es un modelo a elegir.

4.2 Modelo 2.

En el **Modelo 2**, al eliminar esta información clave, el rendimiento disminuyó drásticamente. Aun así, los algoritmos más sofisticados como **XGBoost** y **RandomForest** lograron aprovechar la estructura de las variables sociodemográficas, personales y académicas, alcanzando valores de R^2 cercanos a 0.43. MLP pese a tardar mucho en converger, no ofreció un resultado más alto que los demás. KNN, obtuvo un rendimiento mucho más modesto $R^2 = 0.17$ lo que nos indica que no deberíamos de utilizarlo para predecir modelos de alta dimensionalidad ya que para la distancia definida en el modelo, todos los datos se encuentran muy cerca, lo hemos estudiado como "Curse of dimensionality".

4.3 Conclusiones de los resultados

Desde una perspectiva educativa, este análisis refuerza la importancia de las evaluaciones continuas como herramienta de predicción del rendimiento final. Asimismo, demuestra que incluso en ausencia de calificaciones previas, es posible obtener predicciones peores pero razonables mediante el análisis de

otras características de los alumnos. Estos resultados pueden ser útiles para la detección temprana de riesgo académico o el diseño de intervenciones personalizadas.

Algo muy curioso que se observó en ambos modelos fue que el valor de $l1_ratio \approx 1$ fue elegido como el más óptimo para predecir las variables. Esto significa que el modelo de Regresión lineal con regularización ElasticNet es en realidad un modelo de Regresión lineal con regularización Lasso o L1. Nos lleva a la conclusión de que hay un número de variables que no aportan casi información y perjudican a los algoritmos más de lo que pueden llegar a aportar.

5 Reflexión sobre los factores clave que influyen en el rendimiento académico

5.1 Importancia de variables según modelos RandomForestRegressor

En el **Modelo 1**, que incluye como predictores las notas parciales T1 y T2, se observa una clara dominancia de T2 como variable más influyente, con un peso muy superior al del resto. Le siguen en importancia la interacción T1_T2_interaction y el número de **faltas**. La inclusión de la asignatura (**asignatura_M**) también aporta cierta información. Esta jerarquía de relevancia sugiere que el rendimiento parcial es el factor principal para predecir la nota final. Véase la Figura 3.




Figure 3: Importancia de las variables en el Modelo 1 (Random Forest).

En el **Modelo 2**, como ya no podemos utilizar las notas anteriores para predecir, el número de **suspensos** acumulados es el factor más determinante. A continuación se sitúan las **faltas**, la **edad**, el tipo de asignatura y otras variables de carácter personal como el estado de salud (**SalAm**) o el tiempo libre (**TiempoLib**). Esto refleja que, en ausencia de información académica previa, el contexto del alumno y sus hábitos de estudio cobran mayor protagonismo. Las variables más importantes son indicativas de compromiso, constancia o posibles dificultades académicas. (Figura 4).




Figure 4: Importancia de las variables en el Modelo 2 (Random Forest).

De las variables menos influyentes podemos mencionar varias cosas. Se trata principalmente de atributos administrativos o sociales como el tipo de empleo familiar (**servicios**, **sanidad**), la disponibilidad de enfermería en el centro o el número de hermanos. Esto no implica que dichas variables carezcan totalmente de valor informativo, pero sí que su efecto directo sobre la nota final es mínimo en comparación con otros factores más vinculados al rendimiento o implicación del alumno. Es decir, las variables que aparecen en el gráfico no afectan casi al rendimiento académico del alumno lo que nos podría llevar a la conclusión de que no aportan estrés o dificultades al estudiante

5.2 Análisis de componentes principales (PCA)

Para complementar el análisis anterior, se aplicó **PCA** con el objetivo de reducir la dimensionalidad del conjunto de datos y estudiar la contribución de cada variable en las primeras componentes.

En el **Modelo 1**, las variables que más influyen en las dos primeras componentes principales son **T1**, **T2** y **T1.T2.interaction**, lo que concuerda con lo observado en los modelos supervisados. Estas variables explican buena parte de la varianza del sistema. También destacan en menor medida variables como **Medu**, **Pedu** o **TiempoEstudio**, sin embargo la diferencia entre importancia de variables es mucho menor que con los modelos supervisados (ver Figura 5).




Figure 5: Variables más influyentes en las componentes principales del Modelo 1.

En el **Modelo 2**, donde no se dispone de notas previas, se observa un cambio en el patrón de carga. Variables como **Alc_comb**, **TiempoLib**, **SalAm**, **suspensos** y **faltas** adquieren mayor relevancia. También aparecen variables demográficas como **sexo** o **edad** con una mayor contribución a la varianza explicada (Figura 6).




Figure 6: Variables más influyentes en las componentes principales del Modelo 2.

Adicionalmente, cabe mencionar que las variables menos relevantes en términos de carga en PCA, en su gran mayoría coinciden con las menos influyentes según Random Forest.

Sobre los dos primeros componentes principales obtenidos por PCA, se aplicó un algoritmo de **clustering KMeans** con $k = 2$. La visualización bidimensional (Figura 7) evidencia la existencia de dos agrupaciones relativamente diferenciadas. Este resultado sugiere que existen subgrupos de

estudiantes con perfiles similares, lo que puede ser útil para diseñar intervenciones específicas o detectar casos atípicos. Para definir estos subgrupos se han tenido en cuenta muchas variables como hemos observado en




Figure 7: Distribución de los alumnos según KMeans sobre PCA.

5.3 Conclusiones

Los análisis de importancia de variables y componentes principales apuntan a conclusiones coherentes: las notas previas, el número de suspensos y las faltas son factores clave del rendimiento. Cuando estas no están disponibles, el entorno familiar, el tiempo libre, la salud o el género toman un rol más relevante.

Asimismo, las técnicas de clustering aplicadas sobre PCA evidencian la posible segmentación del alumnado en grupos homogéneos, lo que refuerza la utilidad del aprendizaje no supervisado como herramienta complementaria al análisis predictivo.

6 Parte creativa: exploración adicional

6.1 Dificultad desmesurada entre asignaturas.

Con el objetivo de profundizar en las diferencias de rendimiento entre asignaturas, se representaron las notas finales (T3) segmentadas por categorías cualitativas (suspense, aprobado, bien, notable, sobresaliente) para las materias de Matemáticas y Lengua.

Vemos que la asignatura de Matemáticas parece ser más exigente que la de Lengua, ya que el número de suspensos es sensiblemente mayor, mientras que los sobresalientes se reducen en comparación con Lengua. Esta diferencia sugiere que la dificultad percibida o real de la materia influye considerablemente en la distribución de calificaciones. En Lengua, las notas tienden a concentrarse en los rangos superiores, lo cual puede estar relacionado con criterios de evaluación distintos, el tipo de competencias evaluadas, o un mayor apoyo percibido por parte del alumnado.




Figure 8: Distribución de calificaciones finales (T3) en Matemáticas (M) y Lengua (L).

6.2 Casos atípicos: cambio escolar y rendimiento excepcional

Durante el análisis de los datos, se identificaron varios perfiles de estudiantes con comportamientos extremos o inusuales que merecen atención especial tanto desde una perspectiva académica como educativa.

Alumnos que se desconectan del sistema. Se observó que todos los estudiantes con calificación igual a cero en la segunda evaluación (T2) también obtuvieron un 0 en la tercera evaluación (T3). Esta coincidencia sugiere posibles casos de abandono escolar, traslado a otro centro o inasistencia prolongada. Asimismo, se detectaron otros alumnos con $T3 = 0$ que no presentaban bajo rendimiento en las evaluaciones anteriores, lo que refuerza la hipótesis de causas externas como cambios de residencia o sanciones académicas (por ejemplo, copia). Dado que un 0 es una calificación muy poco común en un examen valorado sobre 20, estos registros son difíciles de predecir mediante modelos convencionales.

Estudiantes con rendimiento excepcional. También se identificaron dos perfiles de alto rendimiento poco convencionales:

- Alumnos que declararon dedicar muy poco tiempo al estudio ($TiempoEstudio = 1$), pero obtuvieron calificaciones finales por encima de 17. Este grupo podría corresponder a estudiantes con altas capacidades intelectuales o métodos de estudio altamente eficientes.
- Alumnos con más de 50 faltas de asistencia, sin suspensos y con notas finales igualmente sobresalientes. Este perfil sugiere una gran autonomía, resiliencia o facilidad de aprendizaje por parte del estudiante.

Estos casos, aunque escasos, resultan muy valiosos desde un punto de vista educativo, ya que permiten identificar perfiles de talento no evidentes y cuestionar ciertos supuestos tradicionales sobre el rendimiento escolar. Su detección puede ser útil para implementar medidas de apoyo diferenciadas o programas de enriquecimiento educativo adaptado.




Figure 9: Distribución de T3 para estudiantes con $TiempoEstudio = 1$. Los puntos rojos indican rendimientos excepcionales.




Figure 10: Distribución de T3 para estudiantes con más de 50 faltas y ningún suspenso. Los puntos naranjas representan outliers de alto rendimiento.